

Archivio XML dei CIG ANAC

Relazione sintetica sulla preparazione documentale

Massimiliano Ricchiuti
Elaborazione di testi e gestione documentale

A.A. 2025/2026

1. Obiettivo e dataset

Il progetto realizza una pipeline Python che processa fonti relative a contratti pubblici, le trasforma in XML, valida i documenti mediante DTD, estrae informazioni e genera una collezione HTML navigabile. Il dataset comprende 15 XML, soglia prevista per il progetto individuale, derivati da fonti CSV, JSON, HTML e PDF conservate in `fonti_originali/`. Il campione è didattico e non rappresenta l'intero universo ANAC.

La preparazione parte dai CIG presenti nei JSON, integra le righe omologhe del CSV e collega le ulteriori fonti. L'associazione non usa eccezioni dedicate: il programma cerca un CIG noto nel nome del file e, se il nome è descrittivo, nel testo estraibile. In questo modo il documento *pn vsf15-25-sua lettera inv.-disciplinare indifferenziata 2025-26 Frascati* viene associato a B6DD95EE23 perché il codice compare nel testo, insieme al PDF ANAC canonico. Lo stesso criterio si applica a nuovi documenti e ad altri CIG.

2. Modello XML e validazione

Ogni radice `contratto` reca il CIG e contiene fonti, informazioni di gara, stazione appaltante, pubblicazioni, partecipanti, importi, date, CPV e descrizione documentale. Per ciascuna fonte sono conservati tipologia, MIME type, percorso e descrizione; le pagine di dettaglio propongono i relativi download.

La DTD `schema/contratto_cig.dtd` stabilisce ordine, cardinalità e attributi. Il requisito del contenuto testuale è soddisfatto da un content model misto conforme alla sintassi XML:

```
<!ELEMENT descrizioneDocumentale
  (#PCDATA | tipologia | oggetto | categoria | termine | luogo)*>
```

L'elemento alterna testo ed elementi semantici ripetibili; il dataset non è quindi composto soltanto da blocchi strutturati. La build valida tutti gli XML con `lxml`; un documento mal formato o non valido interrompe l'esecuzione e viene registrato in `output_data/validation.xml`.

3. Estrazione, analisi e output

Gli XPath convertono gli XML validi in istanze del modello intermedio `ContractRecord`. Su tale modello sono calcolate distribuzioni territoriali, copertura dei campi, sequenze cronologiche, statistiche economiche e frequenze testuali. I PDF sono esaminati con `pypdf`, con ripiego su `pdfminer.six`; gli importi usano `Decimal` e le incongruenze temporali restano visibili senza correzioni arbitrarie.

Jinja2 genera `index.html`, un archivio filtrabile, una pagina per ciascun XML valido, l'analisi del campione, la qualità dei dati e la pagina unificata *Progetto e metodo*. Quest'ultima incorpora metodologia e documentazione, sostituendo le precedenti voci ambigue "Metodologia" e "PDF". Ogni dettaglio contiene parte del contenuto elaborato, il download dell'XML e delle fonti collegate. Tutte le pagine di dettaglio recano microdata `schema.org/GovernmentService`; CSS, JavaScript e grafici SVG sono locali e responsivi.

4. Riproducibilità, verifiche e uso di strumenti AI

I comandi principali sono:

```
python -m pip install -r requirements.txt -r requirements-dev.txt
python scripts/build_all.py
python -m pytest
```

La suite verifica parsing, DTD, estrazione, statistiche, mapping dei documenti descrittivi, pagine, microdata e collegamenti interni. GitHub Actions ripete build e test a ogni push su `main` e pubblica `dist/` su GitHub Pages.

Gli strumenti AI sono stati impiegati per la revisione architetturale, l'implementazione e il controllo della documentazione. Le proposte sono state sottoposte a validazione DTD, test automatici, build completa e ispezione dell'output. I prompt e le finalità d'uso sono riportati in `report/prompts_utilizzati.md`. Le fonti originali, gli script di preparazione, la DTD, gli XML e gli output HTML restano disponibili e ispezionabili.

5. Riscontro dei requisiti

- 15 file XML distinti e validi, con directory di input configurabile;
- DTD creata per il progetto e content model misto effettivamente usato;
- fonti eterogenee CSV, JSON, HTML e PDF, con script di preparazione consegnato;
- una pagina HTML per ogni XML, indice navigabile e pagine aggiuntive di analisi;
- download dell'XML e dei documenti originali collegati al relativo CIG;
- foglio CSS comune, layout responsivo e annotazioni microdata generate;
- relazione entro tre pagine e prompt conservati nella documentazione.

6. Limiti

Il dataset è circoscritto e presenta campi mancanti o semanticamente non omogenei; perciò le analisi sono descrittive. Il riconoscimento automatico richiede che il CIG sia presente nel nome o nel testo estraibile: per PDF costituiti esclusivamente da immagini è necessario un livello OCR. Tali limiti sono dichiarati nel sito e non vengono occultati mediante dati inventati.