

Archivio XML dei CIG ANAC

Pipeline documentale, analisi dei dati e sito statico

Massimiliano Ricchiuti
Elaborazione di testi e gestione documentale

A.A. 2025/2026

Indice

1	Obiettivo e perimetro	2
2	Fonti e provenienza dei dati	2
3	Copertura effettiva dei formati disponibili	2
4	Struttura delle directory	2
5	Architettura del software	3
6	Separazione tra supporto ed elaborazione	3
7	Modello XML	3
8	DTD e validazione	3
9	Modello intermedio dei record	3
10	Pipeline completa	3
11	Metodologia dell'analisi territoriale	4
12	Risultati territoriali	4
13	Metodologia dell'analisi delle scadenze	4
14	Risultati cronologici e anomalie	4
15	Metodologia dell'analisi degli importi	5
16	Risultati economici	5
17	Generazione del sito statico	5
18	Grafica, responsività e accessibilità	6
19	Pubblicazione su GitHub Pages	6
20	Verifiche automatiche	6

21 Riproducibilità	6
22 Uso degli strumenti AI	6
23 Limiti del dataset	6
24 Possibili sviluppi futuri	7

1 Obiettivo e perimetro

Il progetto costruisce un archivio documentale relativo ai CIG ANAC presenti nel repository. Le fonti eterogenee sono trasformate in documenti XML, validate mediante DTD, estratte in un modello intermedio e analizzate sotto il profilo territoriale, cronologico ed economico. Il risultato di pubblicazione è un sito statico autonomo nella directory `dist/`.

Il campione coincide esclusivamente con i documenti inclusi nel progetto. Non è quindi rappresentativo della totalità dei contratti pubblici o delle procedure registrate da ANAC.

2 Fonti e provenienza dei dati

Le fonti originali sono conservate in `fonti_originali/`. Il CSV fornisce il quadro tabellare; i JSON contengono i dati strutturati di dettaglio; gli HTML e i PDF documentano le rispettive rappresentazioni originali. La fase di preparazione individua dinamicamente i CIG presenti nella directory JSON e integra, quando disponibile, la riga corrispondente del CSV. Non viene utilizzato un numero di documenti scritto rigidamente nel codice.

3 Copertura effettiva dei formati disponibili

La copertura è calcolata durante la build esaminando i file effettivamente collegati a ciascun record. Le dichiarazioni precedenti secondo cui solo tre CIG disponevano di fonti complete erano obsolete e sono state rimosse.

Tabella 1: Copertura delle fonti

Formato	Disponibili	Mancanti	Copertura
CSV	15	0	100,0%
JSON	15	0	100,0%
HTML	15	0	100,0%
PDF	15	0	100,0%

Tabella 2: Copertura dei campi data

Campo	Disponibili	Mancanti	Copertura
creation_date	15	0	100,0%
publication_date	15	0	100,0%
offer_deadline	14	1	93,3%
award_date	10	5	66,7%
start_date	3	12	20,0%
expected_end_date	4	11	26,7%

4 Struttura delle directory

L'albero semplificato è il seguente:

```
.
|-- documenti_xml/      XML generati e validati
|-- fonti_originali/    CSV, JSON, HTML e PDF
|-- schema/             DTD
|-- src/
|   |-- support/        componenti riutilizzabili
|   |-- processing/     elaborazioni applicative
|-- scripts/            entry point essenziali
|-- site/               template e asset
|-- output_data/        risultati intermedi
|-- report/             relazione e frammenti generati
|-- tests/              test automatici
'-- dist/               sito statico pubblicabile
```

5 Architettura del software

L'architettura separa configurazione, I/O, parsing, formattazione e validazione dalle elaborazioni del dominio. Gli entry point in `scripts/` invocano funzioni esplicite e non contengono lunghe procedure né importazioni dinamiche dei vecchi file numerati.

6 Separazione tra supporto ed elaborazione

Il package `src/support/` comprende percorsi, lettura e scrittura sicura, parsing XML, DTD, date, importi, formattazione italiana, normalizzazione territoriale, dataclass, controllo dei collegamenti e logging. Il package `src/processing/` comprende preparazione, validazione, estrazione, analisi, grafici, sito, analisi PDF e testuale, microdata e report.

Le funzioni di supporto non decidono quali analisi eseguire. Tale scelta resta nei moduli di elaborazione.

7 Modello XML

Ogni file XML rappresenta un contratto e mantiene sezioni distinte per fonti, informazioni di gara, stazione appaltante, pubblicazioni, partecipanti, aggiudicazione, esecuzione, quadro economico, categorie, CPV e descrizione documentale. La localizzazione della gara, la città della stazione appaltante, la provincia e la regione rimangono campi distinti.

La sezione `descrizioneDocumentale` conserva un modello a contenuto misto, con testo ed elementi semantici interni quali `tipologia`, `oggetto`, `categoria`, `termine` e `luogo`.

8 DTD e validazione

La DTD in `schema/contratto_cig.dtd` definisce ordine, cardinalità e attributi degli elementi. La build analizza ogni XML con un parser configurato senza accesso di rete e produce `output_data/validation.xml`. La presenza di un XML non valido interrompe la build con un messaggio comprensibile.

9 Modello intermedio dei record

Gli XPath sono concentrati nel modulo di estrazione, che produce istanze della dataclass `ContractRecord`. Il modello comprende CIG, oggetto, tipologia, stato, stazione appaltante, campi territoriali distinti, tre importi, sei campi data, CPV, partecipanti, fonti e validità XML. Le funzioni di presentazione non interrogano ripetutamente gli XML.

10 Pipeline completa

Il flusso può essere rappresentato come segue:

```
CSV + JSON + HTML + PDF
      |
      v
preparazione XML
      |
      v
validazione DTD
      |
      v
estrazione ContractRecord
      |
      v
analysis.json + analisi PDF/testo
      |           |
```

v

CIG	Segnalazione	Pubblicazione	Scadenza	Aggiudicazione
B675CE0615	Scadenza anteriore alla pubblicazione	2025-04-14	2025-04-11T11:32	2025-04-10
B675CE0615	Aggiudicazione anteriore alla pubblicazione	2025-04-14	2025-04-11T11:32	2025-04-10
B675CE0615	Aggiudicazione anteriore alla scadenza	2025-04-14	2025-04-11T11:32	2025-04-10
B6A106A32A	Data mancante	2025-04-28	2025-05-08T07:30	n.d.
B74941928B	Data mancante	2025-06-16	2025-07-17T13:00	n.d.
B7B0353822	Data mancante	2025-07-17	2025-08-27T12:00	n.d.
B8297EE856	Scadenza anteriore alla pubblicazione	2025-09-09	2025-09-08T15:42	2025-09-29
B82A8FBA72	Scadenza anteriore alla pubblicazione	2025-09-09	2025-09-08T19:26	2025-10-31
B82CB38B8D	Data mancante	2025-09-09	n.d.	n.d.
B85DEBAAC9	Scadenza anteriore alla pubblicazione	2025-09-25	2025-09-24T14:19	2025-09-24
B85DEBAAC9	Aggiudicazione anteriore alla pubblicazione	2025-09-25	2025-09-24T14:19	2025-09-24

Alcune date possono riferirsi a registrazioni o pubblicazioni successive rispetto allo svolgimento effettivo della procedura. In assenza di ulteriori prove, le incongruenze non sono attribuite automaticamente a errori della fonte.

15 Metodologia dell'analisi degli importi

Il parser monetario gestisce punto e virgola come separatori decimali o delle migliaia, simboli valutari, spazi e valori nulli. I calcoli utilizzano `Decimal`. Per ogni campo sono prodotti disponibilità, somma, media, mediana, minimo, massimo, quartili e intervallo interquartile.

La mediana è riportata separatamente dalla media, poiché una distribuzione asimmetrica non può essere sintetizzata adeguatamente con la sola media. Gli eventuali valori anomali sono individuati tramite la regola di 1,5 volte l'intervallo interquartile.

16 Risultati economici

Tabella 5: Statistiche economiche del campione

Campo	Disponibili	Mancanti	Somma	Media	Mediana	Q1	Q3
Importo gara	15	0	3.482.410,72 €	232.160,71 €	96.150,00 €	76.358,24 €	359.900,00 €
Importo lotto	15	0	3.209.735,72 €	213.982,38 €	96.150,00 €	76.358,24 €	254.250,00 €
Importo aggiudicazione	10	5	1.986.823,79 €	198.682,38 €	90.193,08 €	76.287,35 €	175.898,48 €

Quando importo di gara e importo di aggiudicazione sono entrambi disponibili e positivi, la pipeline calcola differenze assolute e percentuali. Tali scostamenti non sono denominati automaticamente “ribassi”, poiché l'interpretazione dipende dal significato amministrativo dei campi.

17 Generazione del sito statico

Il sito è prodotto con Jinja2 e comprende pagina iniziale, archivio, report, dettaglio di ogni CIG, metodologia e qualità dei dati. Gli asset sono separati in `site/assets/`; il CSS non è generato come stringa Python. Tutti i file necessari vengono copiati in `dist/`.

18 Grafica, responsività e accessibilità

La grafica adotta una gerarchia tipografica sobria, KPI, pannelli, tabelle scorrevoli su schermi ridotti, stati di focus, navigazione adattiva e foglio di stampa. Le pagine di dettaglio includono breadcrumb e microdata. I grafici sono SVG locali con titolo, descrizione e valori testuali; i dati sono inoltre presentati in tabelle alternative.

I grafici presenti nel sito rappresentano città delle stazioni appaltanti, regioni, fasce di importo e distribuzione mensile delle scadenze.

19 Pubblicazione su GitHub Pages

Il workflow `.github/workflows/pages.yml`, eseguito a ogni push sul branch `main`, installa le dipendenze, genera il sito con `python scripts/build.py`, esegue i test e pubblica esclusivamente la directory `dist/`. La build GitHub Pages non richiede LaTeX. L'output include il file `.nojekyll`; i collegamenti relativi restano validi anche nel percorso di progetto `/anac-progetto-team/`.

20 Verifiche automatiche

La build controlla validità XML, generazione delle pagine, microdata e collegamenti interni. Il link checker esamina gli attributi `href`, `src` e `data-src` nella sola directory pubblicata e interrompe il processo se un riferimento locale non esiste o esce da `dist/`.

I test `pytest` verificano parser monetari e temporali, normalizzazione, estrazione, DTD, anomalie, statistiche, pagine principali, collegamenti e file indispensabili al deploy.

21 Riproducibilità

I comandi principali sono:

```
python -m venv .venv
source .venv/bin/activate          # Linux/macOS
python -m pip install -r requirements.txt
python -m pip install -r requirements-dev.txt
python scripts/build_all.py
pytest
```

Su Windows l'attivazione è `.venv\Scripts\activate`. Per una build senza rigenerazione degli XML e senza compilazione LaTeX si usa `python scripts/build.py`.

22 Uso degli strumenti AI

Gli strumenti AI sono stati impiegati per analizzare la struttura, proporre e implementare la rifattorizzazione, rivedere la modellazione, ampliare le analisi e aggiornare la documentazione. Gli output sono stati verificati eseguendo la pipeline, i test, la validazione DTD, il controllo dei link e, quando disponibile, la compilazione LaTeX. I prompt sono documentati in `report/prompts_utilizzati.md`.

23 Limiti del dataset

Il campione è piccolo e selezionato in base ai documenti disponibili nel progetto. Non consente inferenze sull'intero universo ANAC. Alcuni campi sono mancanti; le localizzazioni possono avere granularità differenti; le date possono riflettere momenti amministrativi diversi; gli importi non sempre sono semanticamente confrontabili.

24 Possibili sviluppi futuri

Sviluppi plausibili comprendono l'ampliamento del campione, un vocabolario controllato per le tipologie, schemi XML più espressivi, test di accessibilità automatizzati, confronto tra versioni dei dati e ulteriori visualizzazioni. Tali estensioni dovrebbero preservare la separazione tra supporto, analisi e presentazione.